固定 1,800 张测试集：正式服务器评测

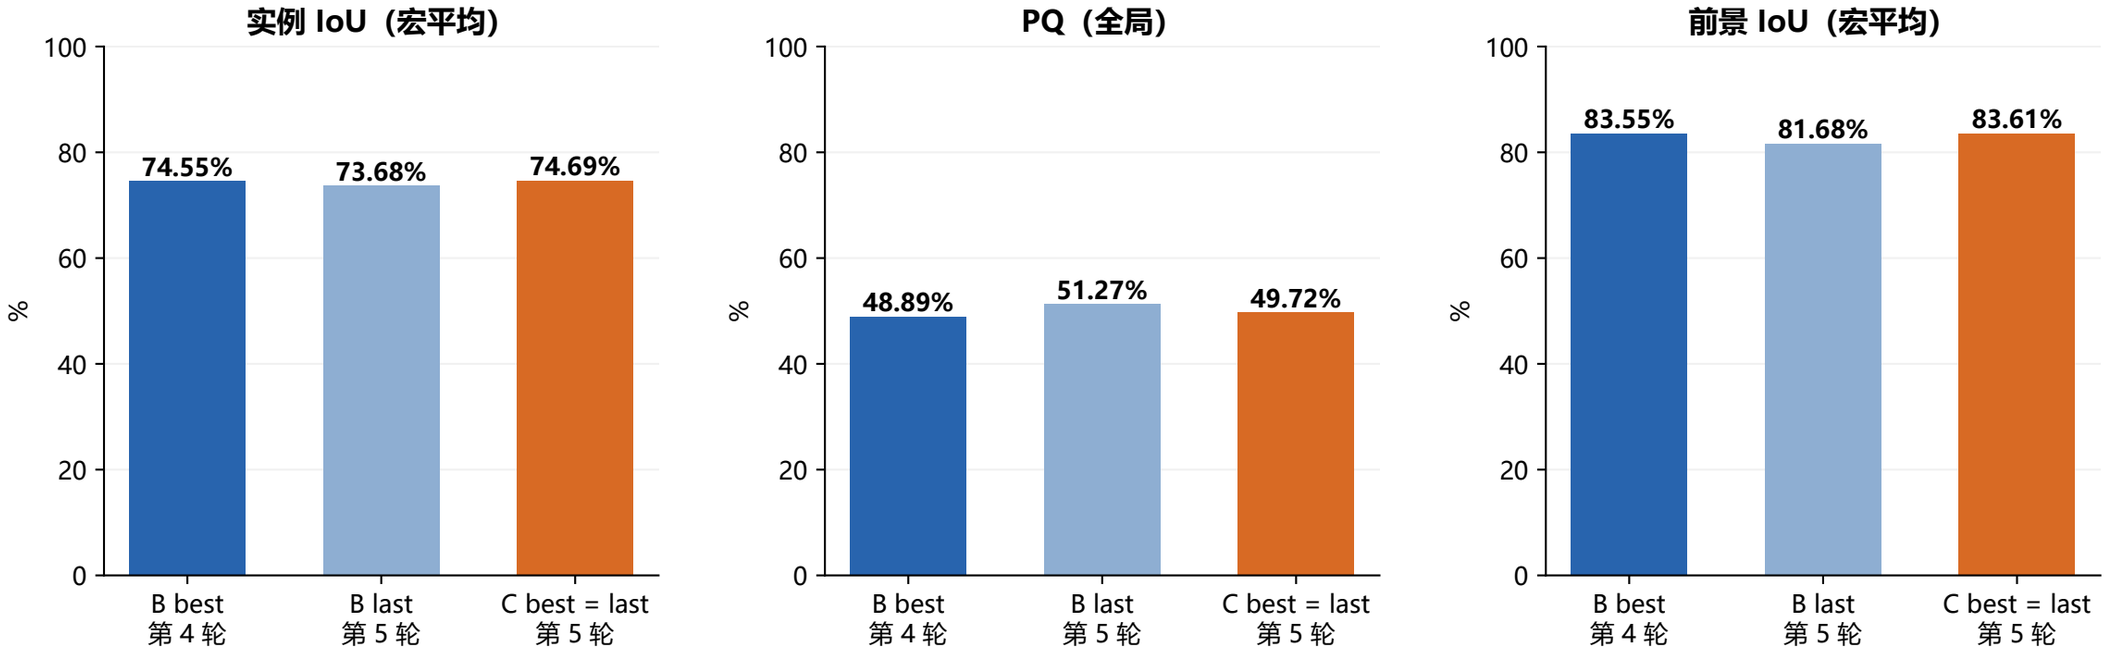

best 只由验证集选择；阈值固定 0.5；四份测试报告均 0 失败。这里没有根据测试成绩改选 checkpoint。